

Informatik Cheat Sheet

Formale Sprachen

(Noam) Chomsky-Hierarchie (50er Jahre):

- Typ 0 rekursiv aufzählbare Sprachen: Turing-Maschine
- Typ 1 kontextsensitive Grammatiken: ohne praktische Bedeutung
- Typ 2 kontextfreie Grammatiken: Kellerautomat
- Typ 3 reguläre Ausdrücke: endlicher Automat

Definitionen

Alphabet ist eine endliche, nicht leere Menge von Symbolen
($\Sigma = \{a, b, c, \dots\}$)

Zeichenreihe ist eine endliche Folgen von Symbolen eines Alphabets
($w|x|y|z$) Synonyme: Wort, String.

Leere Zeichenreihe enthält keine Symbole und wird als ϵ dargestellt.

Länge bezeichnet die Anzahl Symbole einer Zeichenreihe ($|w|$)

Σ^k Die Menge aller Zeichenreihen über dem Alphabet Σ mit der Länge k . $\Sigma^0 = \{\epsilon\}$

Σ^* Die Menge aller Zeichenreihen über einem Alphabet.
 $\Sigma^* = \Sigma^0 \cup \Sigma^1 \cup \dots$

Σ^+ Die Menge aller nichtleeren Zeichenreihen über einem Alphabet.
 $\Sigma^+ = \Sigma^* \setminus \Sigma^0$

Konkatenation bezeichnet die Verbindung zweier Zeichenreihen x und y zu xy . Es gilt:

- $x \neq y \Leftrightarrow xy \neq yx$
- $|xy| = |x| + |y|$
- $w\epsilon = \epsilon w = w$ (ϵ ist das neutrale Element)

Sprache ist eine Menge von Zeichenreihen aus Σ^* die als Sprache L über dem Alphabet Σ bezeichnet wird.

Es seien $s(L) := L$ ist eine Sprache, $c(w(L_1), w(L_2)) :=$ Die Menge aller Konkatenation von eines beliebigen $w \in L_1$ und einem beliebigen $w \in L_2$.

- Das Alphabet ist immer endlich, aber es kann unendliche viele Wörter geben.
- \emptyset ist die leere Sprache für jedes Alphabet Σ
- Σ^* ist eine Sprache für jedes Alphabet Σ
- $L \subseteq \Sigma^*$
- $\Sigma_1 \subseteq \Sigma_2 \wedge L \subseteq \Sigma_1^* \Rightarrow L \subseteq \Sigma_2^*$
- $\{\epsilon\}$ ist die Sprache, die aus der leeren Zeichenkette ϵ besteht ($\emptyset \neq \epsilon$)
- Vereinigung: $s(L) \wedge s(M) \Rightarrow s(L \cup M)$
- Konkatenation: $s(L) \wedge s(M) \Rightarrow s(c(w(L), w(M)))$
- (Kleensche) Hülle, Stern: $s(L) \Rightarrow s(L^*)$ mit $L^* = \{c(w(L), w(L))\}$

Problem bezeichnet die Entscheidung, ob eine Zeichenreihe w aus Σ^* in einer Sprache L über dem Alphabet Σ enthalten ist.
D. h. Entscheidung ob eine Zeichenreihe zu einer Sprache gehört oder nicht

Notationen

Folgenden Definitionen sind synonym:

$$L = \{1^n 0^n | n \in \mathbb{N}\}$$

$$L = \{\epsilon, 10, 1100, 111000, \dots\}$$

$$L = \{w | w \text{ enthält } n \cdot 1 \text{ gefolgt von } n \cdot 0 \text{ für } n \in \mathbb{N}\}$$

L ist die Menge aller Zeichenreihen über dem Alphabet $\{0, 1\}$,
die aus n Einsen und n Nullen besteht

Reguläre Ausdrücke

- ϵ und \emptyset sind reguläre Ausdrücke und beschreiben die Sprache $L(\epsilon) = \epsilon$ bzw. $L(\emptyset) = \emptyset$
- Wenn a ein Symbol ist, dann ist a auch ein regulärer Ausdruck und beschreibt die Sprache $L(a) = \{a\}$.
- Wenn R ein regulärer Ausdruck ist, dann ist auch (R) ein regulärer Ausdruck, der die gleiche Sprache spezifiziert:
 $L((R)) = L(R)$ d. h. Klammern sind optional und dienen der Lesbarkeit.
- Wenn R_1 und R_2 reguläre Ausdrücke sind, dann ist auch $R_1 + R_2$ ein regulärer Ausdruck und es gilt:
 - $L(R_1 + R_2) = L(R_1) \cup L(R_2)$
 - $L(R_1 R_2) = L(R_1) L(R_2)$
- Wenn R ein regulärer Ausdruck ist, dann ist auch R^* ein regulärer Ausdruck und es gilt: $L(R^*) = (L(R))^*$

Reihenfolge Auswertung: $R^* > R_1 R_2 > R_1 + R_2$
 $R? = R + \epsilon$ (Auftreten: ein oder keinmal)

Erweiterungen (Unix)

$.$ beliebiges Zeichen
 $[a_1, a_2, \dots, a_n]$ Folgen
 $[\dots]$ Bereichsangaben wie [0-9] oder Schlüsselwörter

Gesetze

Kommutativgesetz $L + M = M + L$
Assoziativgesetz $(L + M) + N = L + (M + N)$
Verkettung $(LM)N = L(MN)$
Distributivgesetz $L(M + N) = LM + LN$
Idempotenzgesetz $L + L = L$

Rechenregeln

$$\begin{aligned} \emptyset + L &= L = L + \emptyset & \{\epsilon\}^* &= \{\epsilon\} \\ \{\epsilon\}L &= L = \{L\epsilon\} & LL^* &= L^*L = L^+ \\ \emptyset L &= \emptyset = L\emptyset & (L^*)^* &= L^* \\ \emptyset^* &= \{\epsilon\} & L^* &= L + \{\epsilon\} \end{aligned}$$

Anwendungen:

- Mustersuche in Texten
- Lexikalische Analyse (Compiler), Erkennung von Schlüsselwörtern („Token“)
- Darstellung von Symbolmengen
- Nachweis der Gültigkeit von gültigen Gesetzen (Gleichheit regulärer Ausdrücke) wird auf die Frage der Gleichheit der Sprachen reduziert (via endliche Automaten, Minimierung und Vergleich)

Automatentheorie

(Stephan Kleene, Michael Rabin, Dana Scott, 40er/50er Jahre)

Endliche Automaten (EA)

5-Tupel: $\mathcal{A} = (Q, \Sigma, \delta, q_0, F)$

$Q = \{q_0, \dots, q_n\}$ endliche Menge von Zuständen

$\Sigma = \{a_0, \dots, a_m\}$ Eingabe-Alphabet

$\delta : Q \times \Sigma \rightarrow Q$ Übergangsfunktion

$q_0 \in Q$ Startzustand

$F = \{q_0, \dots, q_p\}$ Akzeptierende Endzustände

Deterministischer endlicher Automat (DEA) Geht auf Grund einer Eingabe von einem Zustand in genau einen Zustand über.

Nichtdeterministischer endlicher Automat (NEA) Geht auf Grund einer Eingabe in einen von mehreren Zuständen über.

$$\delta : Q \times \Sigma \rightarrow \mathcal{P}(Q)$$

ϵ -NEA wie NEA, erlaubt ϵ als Eingabe \Rightarrow kann spontan wechseln.

Erweiterte Übergangsfunktion Ein Automat verarbeitet einem Reihe von Eingabesymbolen (das Eingabewort) in dem er mit Hilfe der Übergangsfunktion δ den jeweiligen Folgezustand ermittelt: $\delta(q_0, a_0) = q_1, \delta(q_1, a_1) = q_2, \dots$

Dies wird als erweiterte Übergangsfunktion $\hat{\delta} : Q \times \Sigma \rightarrow Q$ (d. h. $\hat{\delta}(q_0, w) = q_n$) definiert

Akzeptieren Ein Eingabewort w wird dann akzeptiert, wenn $\hat{\delta}$ für w in einen akzeptierenden Endzustand $q_n \in F$ führt.

Sprache bezeichnet die Menge aller Zeichenreihen, die der Automat akzeptiert: $L(A) = \{w | \delta(q_0, w) \rightarrow q_n \in F\}$


Beispiel

Gesucht wird ein endlicher Automat \mathcal{A} der die Sprache $L = \{x01y | x, y \in \Sigma^* \text{ mit } \Sigma = \{0, 1\}\}$ akzeptiert.

Lösung (DEA):

$$\mathcal{A} = (\{q_0, q_1, q_2\}, \{0, 1\}, \delta, q_0, \{q_2\})$$


$$\delta = \{\delta(q_0, 1) = q_0, \delta(q_0, 0) = q_1, \delta(q_1, 0) = q_1, \delta(q_1, 1) = q_2, \delta(q_2, 0) = q_2, \delta(q_2, 1) = q_2\}$$



Lösung (NEA):

$$\mathcal{A} = (\{q_0, q_1, q_2\}, \{0, 1\}, \delta, q_0, \{q_2\})$$

$$\delta = \{\delta(q_0, 1) = \{q_0\}, \delta(q_0, 0) = \{q_0, q_1\}, \delta(q_1, 1) = \{q_2\}$$



Es gilt: $RA \Leftrightarrow DEA \Leftrightarrow NEA \Leftrightarrow \epsilon$ -NEA

Eigenschaften regulärer Sprachen

Sind L_1 und L_2 reguläre Sprachen, dann gilt:

Vereinigung	$L_1 \cup L_2$ ist regulär
Durchschnitt	$L_1 \cap L_2$ ist regulär
Komplement	L_1^C ist regulär
Verkettung	$L_1 + L_2$ ist regulär
Differenz	$L_1 - L_2$ ist regulär
Hülle	L_1^* und L_1^+ sind regulär
Homomorphismus	$h(L_1)$ und $h^{-1}(L_1)$ sind regulär
Spiegelung	L_1^R ist regulär

Entscheidbarkeit regulärer Sprachen

Gegeben sei eine reguläre Sprache L

Ist L leer? entscheidbar

$w \in L$? entscheidbar

$L_1 = L_2$? entscheidbar


Pumping-Lemma

Sei L eine reguläre Sprache. Dann gibt es eine Konstante n , so dass jeder Zeichenreihe $w \in L, |w| > n$, in drei Teilzeichenreihen $w = xyz$ wie folgt zerlegt werden kann:

$$y \neq \epsilon$$

$$|xy| \leq n$$

$$xy^kz \in L, \text{ für alle } k \geq 0$$



Kann für eine Sprache gezeigt werden, dass sie das Pumping-Lemma nicht erfüllt, ist sie nicht regulär.

Pro Memoria: Moore- & Mealy-Automat

Beide Typen sind logisch äquivalent und lassen sich ineinander überführen. Beide unterscheiden sich von den endlichen Automaten dadurch, dass sie neben finalen Zuständen auch eine Ausgabe erzeugen. Sie werden als 7-Tupel definiert:

$$\mathcal{A} = (Q, \Sigma, \Omega, \delta, \lambda, q_0, F)$$

Q endliche Menge von Zuständen

Σ endliches Eingabealphabet

Ω endliches Ausgabealphabet

δ Übergangsfunktion $\delta : Q \times \Sigma \rightarrow Q$

λ Ausgabefunktion $\lambda : Q \rightarrow \Omega$

q_0 Startzustand

F endliche Menge finaler Zustände ($F \subset Q$)

Moore-Automat Die Ausgabe wird mit dem Zustand assoziiert und hängt somit nur vom Zustand ab.

Mealy-Automat Die Ausgabe wird mit der Transition assoziiert, dass heisst, sie hängt vom Zustand und der Eingabe ab. Beim Zustandswechsel wird zusätzlich etwas ausgegeben.

Kontextfreie Grammatik (kfG)

Eine kontextfreie Grammatik wird als 4-Tupel definiert:

$$G = (V, T, P, S)$$

V Endliche Menge von Zeichenreihen (A, B, C, \dots)

T Endliche Menge von Terminalsymbolen (a, b, c, \dots)

P Endliche Menge von Produktionen/Regeln, definieren die Sprache rekursiv ($A \rightarrow AA$)

S Das Startsymbol ($S \in V$)

Beispiel: Palindrome ($\Sigma = \{0, 1\}$)

$$G_P = (\{A\}, \{0, 1\}, P, A)$$

$$P : A \rightarrow \epsilon, A \rightarrow 0, A \rightarrow 1, A \rightarrow 0A0, A \rightarrow 1A1$$

$$\text{oder } P : A \rightarrow \epsilon[0|1|0A0|1A1$$

Ableitungsschritt Gegeben sei eine kfG G und ein Wort $\alpha A \beta$, mit α und β sind Wörter aus $V \cup T$ und $A \in V$ sowie einer Produktion $A \rightarrow \gamma \in P$. Dann ist die Relation $\alpha A \beta \Rightarrow \alpha \gamma \beta$ ein Ableitungsschritt in G .

Beispiel: $0A0 \Rightarrow 00A00$ ist ein Ableitungsschritt.

Ableitung Ein Ableitungsschritt kann zu einer Ableitung aus $0 - n$ Ableitungsschritten erweitert werden: $\alpha \xRightarrow{G} \gamma$ ist eine

Ableitung in G .

Beispiel:

$$A \xRightarrow{G} 1101011 : A \xRightarrow{G} 1A1 \xRightarrow{G} 11A11 \xRightarrow{G} 110A011 \xRightarrow{G} 1101011$$

Um Ableitungsschritte zu definieren empfiehlt sich:

1. Ausdrucksproduktionen (A) bestimmen (z. B. $A \rightarrow A + A$)
2. Bezeichnerproduktionen (B) bestimmen (z. B. $B \rightarrow a|b| \dots |z$)
3. Ausdrücke ableiten (von links oder von rechts: $A \xRightarrow{G} A + A$)
4. Bezeichner ableiten (von links oder rechts, aber gleich wie im vorherigen Schritt: $A + A \xRightarrow{G} a + A \xRightarrow{G} a + b$)

Linksseitige Ableitung in jedem Schritt wird die äusserste linke Variable durch eine Produktion ersetzt: $\alpha \xRightarrow{lm} \gamma$.

Rechtsseitige Ableitung in jedem Schritt wird die äusserste rechte Variable durch eine Produktion ersetzt: $\alpha \xRightarrow{rm} \gamma$.

Sprache der kfG Menge der Zeichenreihen aus terminalen Symbolen, die sich vom Startsymbol ableiten lassen:

$$L(G) = \{w | S \xRightarrow{G} w \wedge w \in T^*\}$$

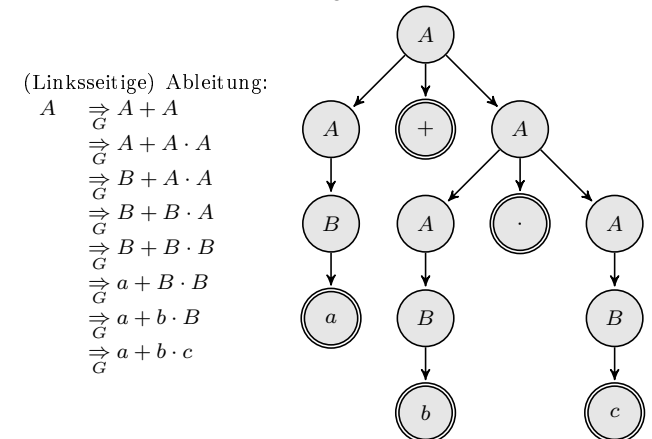
Parsebäume

- stellen Ableitungen als Bäume dar
- verdeutlichen wie terminale Wörter aus Teilwörtern strukturiert sind
- werden von Compilern erzeugt: Datenstruktur, die Quellprogramme repräsentiert

Gegeben sei eine kfG $G = (V, T, P, S)$. Ein Baum ist ein Parsebaum von G wenn:

1. Alle inneren Knoten mit einer in V enthaltenen Variable bezeichnet sind
2. Für jedes Blatt gilt, dass es entweder
 - mit einer Variablen aus V
 - einem terminalen Symbol aus T oder
 - dem leeren Wort ϵ bezeichnet ist, dann muss das Blatt aber das einzige des Vorgängerknotens sein
3. Für alle innere Knoten gilt (A = Bezeichnung des Knotens und X_1, \dots, X_n Bezeichnung der Nachfolgerknoten von links nach rechts): $(A \rightarrow X_1, \dots, X_n) \in P$

Beispiel Programm-Ausdruck: $A \xRightarrow{G} a + b \cdot c$:



(Linksseitige) Ableitung:

$$\begin{aligned} A &\xRightarrow{G} A + A \\ &\xRightarrow{G} A + A \cdot A \\ &\xRightarrow{G} B + A \cdot A \\ &\xRightarrow{G} B + B \cdot A \\ &\xRightarrow{G} B + B \cdot B \\ &\xRightarrow{G} a + B \cdot B \\ &\xRightarrow{G} a + b \cdot B \\ &\xRightarrow{G} a + b \cdot c \end{aligned}$$

Die Blätter eines Parsebaums ergeben von links nach rechts gelesen eine Zeichenreihe einer kfG $G = (V, T, P, S)$ wenn:

1. Die Wurzel mit dem Startsymbol bezeichnet ist
2. Alle Blätter mit terminalen Symbolen oder ϵ bezeichnet sind

Die Sprache $L(G)$ ist genau die Menge an Zeichenreihen, die sich aus der von links nach rechts gelesenen Zeichen der Blätter aller Parsebäume ergeben.

Mehrdeutigkeit

- Anwendungen (Programmiersprachen) erfordern, dass die mit einer kfG erzeugten Strukturen eindeutig sind
- Nicht jede kfG ist eindeutig
- Es gibt Sprachen, für die jede kfG immer mindestens einer Zeichenkette mehr als eine Struktur zuordnen. Diese Sprachen heissen „inhärent mehrdeutig“. Im Beispiel ($A \xRightarrow{G} a + b \cdot c$) kann nicht erkannt werden ob $a + (b \cdot c)$ oder $(a + b) \cdot c$ zu rechnen ist (Aus der linksseitigen Ableitung ergibt sich $a + (b \cdot c)$, aus der rechtsseitigen ergäbe sich das andere).

Ein Sprache ist mehrdeutig, wenn für mindestens eine Zeichenreihe mehr als ein Parsebaum existiert.

Häufig (aber nicht immer) lässt sich eine kfG so anpassen, dass sie eindeutig wird.

Mehrdeutigkeit eliminieren

Das Beispiel $A \xrightarrow{\cdot} a + b \cdot c$ wird eindeutig durch:

- erzwungene Klammern oder
- angepasste Produktionen, so dass $\cdot > +$
- Linksableitung vorgeben $A \rightarrow A + A | A \cdot A | (A)$ (Addition wird vor der Multiplikation, die wiederum vor der Klammer aufgelöst)

Anwendungen

- Beschreibung natürlicher Sprachen (N. Chomsky): allerdings sind kfG nicht für natürliche Sprachen geeignet, weil Mehrdeutigkeiten häufig vom Kontext abhängen
- Compiler: Klammern, Blöcke, Bedingungen erfordern KfG, für andere Komponenten reichen reguläre Ausdrücke (z.B. $A \rightarrow \epsilon | \text{if}(A) \text{else if}(A) | AA$)
- Parsergeneratoren (Quellcode \rightarrow Parsebaum):
 - Bezeichner werden über lexikalische Analyse erkannt
 - Strukturen werden über kfG erkannt
- Markupsprachen (z.B. HTML): wie Parsegeneratoren
- XML: (kfG beschreibt die Semantik über die DTD(Dokumentendefinition))

Pushdown-Automaten (=Kellerautomaten)

Sind im Gegensatz zu endlichen Automaten unendliche Automaten.

Pushdown-Automat (PDA) Ein (nichtdeterministischer)

Pushdown-Automat P wird als 7 Tupel definiert:

$P = (Q, \Sigma, \Gamma, \delta, q_0, s_0, F)$

Q endliche Menge von Zuständen

Σ endliches Eingabealphabet

Γ endliches Stackalphabet

δ Übergangsfunktion $\delta: Q \times (\Sigma \cup \{\epsilon\}) \times \Gamma \rightarrow \mathcal{P}(Q \times \Gamma^*)$

q_0 Startzustand ($q_0 \in Q$)

s_0 Startsymbol des Stacks ($s_0 \in \Gamma$)

F Menge der akzeptieren Zustände ($F \subset Q$)

Die Übergangsfunktion δ bildet das Tripel

$\delta(q_v \in Q, e \in \Sigma, s_v \in \Gamma)$ auf eine endliche Menge von Paaren ($q_n \in Q, s_n \in \Gamma$) ab. Die Indexe n und v stehen dabei für vorher (v) respektive nachher (n).

Stack Ein Stack ist ein Last In – First Out (LIFO) Speicher. Ein PDA liest das oberste Elemente $x \in \Gamma$ und ersetzt es durch $\gamma \in \Gamma$.

- $\gamma = \epsilon$ („pop“, entfernt oberstes Element)
- $\gamma = x$ („void“, Stack unverändert)
- $\gamma \neq x \wedge \gamma \neq \epsilon$ („pop/push“, ersetzt oberstes Element)
- Ist $|\gamma| > 1$ entspricht einem „pop“ und $|\gamma|$ „pushs“.

Konfiguration Das Tripel (q, w, γ) wird als Konfiguration K von P bezeichnet.

q aktueller Zustand

w noch nicht gelesener Teil der Eingabealphabet

γ Inhalt des Stacks

Bewegung Sei (p, α) ein Element von $\delta(q, e, s)$, dann stellt ein Wechsel von Konfiguration $(q_v, ew, s\beta)$ nach $(q_n, w, \alpha\beta)$ eine Bewegung dar: $(q_v, ew, s\beta) \vdash_P (q_n, w, \alpha\beta)$

Berechnung Gegeben sei ein PDA und eine Folge von Konfigurationen K_1, \dots, K_n für die paarweise gilt: $K_i \vdash K_{i+1}$ ist eine Bewegung, dann stellt die Folge der Konfigurationen eine Berechnung vom PDA dar (analog $\hat{\delta}$): $K_1 \vdash_P K_n$

Sprache (Endzustand) Die Menge aller Zeichenreihen w , für die in P ausgehend von der Anfangskonfiguration K_0 eine Berechnung existiert, so dass P in einen akzeptierenden Endzustand wechselt wird mit $L(P)$ bezeichnet.

$$L(P) = \{w | (q_0, w, s_0) \vdash_P (f, \epsilon, \beta) \wedge f \in F\}$$

P akzeptiert durch seinen Endzustand. Der Stack spielt keine Rolle.

Sprache (leerer Stack) Die Menge aller Zeichenreihen w für die in P_N ausgehend von einer Anfangskonfiguration K_0 eine Berechnung existiert, so dass P nach dem Einlesen von w einen leeren Stack aufweist wird mit $N(P)$ bezeichnet.

$$N(P) = \{w | (q_0, w, s_0) \vdash_P (f, \epsilon, \epsilon)\}$$

P akzeptiert durch leeren Stack. Der Zustand spielt keine Rolle d.h. es gibt keine Endzustände, d.h.


$P = (Q, \Sigma, \Gamma, \delta, q_0, s_0)$ (6-Tupel!)

Der Automat schreibt also ein ϵ , wenn er s_0 im Keller hat und die Eingabe ϵ liest.

Beispiel (akzeptiert durch Endzustand)

Ein Automat, der die Sprache $L = \{a^n b^n | n > 0\}$ erkennt:

$$P = (\{q_0, q_1, q_2\}, \{a, b\}, \{a, s_0\}, \{(q_0, w, s_0) \vdash (q_3, \epsilon, \epsilon)\}, q_0, s_0, q_2)$$



Der Automat führt beispielsweise die Berechnung

$(q_0, aabb, s_0) \vdash (q_3, \epsilon, s_0)$ durch. Die Bewegungen dabei sind:

$$(q_0, aabb, s_0) \vdash (q_0, abb, as_0) \vdash (q_0, bb, aas_0) \vdash (q_1, b, as_0) \vdash (q_1, \epsilon, s_0) \vdash (q_2, \epsilon, s_0)$$

Sätze

Gegeben sei ein PDA $P = (Q, \Sigma, \Gamma, \delta, q_0, s_0, F)$:

- Wenn $(q, x, \alpha) \vdash_P (p, y, \beta)$ eine Berechnung in P ist, dann gilt für alle $w \in \Sigma^*$ und alle $\gamma \in \Gamma^*$, dass auch $(q, xw, \alpha\gamma) \vdash_P (p, yw, \beta\gamma)$ eine Berechnung in P ist.

- Wenn $(q, xw, \alpha) \vdash_P (p, yw, \beta)$ eine Berechnung in P ist, dann ist auch $(q, x, \alpha) \vdash_P (p, y, \beta)$ eine Berechnung in P (Umkehrung von 1)
- Aber aus $(q, x, \alpha\gamma) \vdash_P (p, \gamma, \beta\gamma)$ folgt nicht, dass auch $(q, x, \alpha) \vdash_P (p, y, \beta)$ eine Berechnung ist, weil die Eingabe „verbraucht“ wird.
- Für jeden Automaten P_N , der durch leeren Stack akzeptiert, gibt es auch einen Automaten P_L , der durch den Endzustand akzeptiert: $L = N(P_N) = L(P_L)$
- Für jeden Automaten P_L , der durch Endzustand akzeptiert, gibt es auch einen Automaten P_N , der durch leeren Stack akzeptiert: $L = L(P_L) = N(P_N)$.
- $L(G) \Leftrightarrow L(P) \Leftrightarrow L(P)$ (mit G ist eine kfG).

Deterministischer PDA (DPDA)

Ein PDA ist deterministisch wenn:

1. $\delta(q, a, s)$ höchstens ein Element enthält
2. $\delta(q, a, \gamma) \neq \emptyset \Rightarrow \delta(q, \epsilon, \gamma) = \emptyset$

Ein DPDA P kann in jeder Konfiguration höchstens eine Bewegung ausführen. Er kann reguläre Sprachen erkennen, aber nicht alles, was ein PDA erkennen kann.

$$L^*(DEA) = L^*(NEA) = L^*(\epsilon NEA) \subsetneq L^*(DPDA_E) \subsetneq L^*(PDA)$$

$DPDA_E$ steht für einen Automaten, der durch Endzustand akzeptiert.

Für eine Sprache L und einen DPDA P , der über leeren Stack akzeptiert, gilt $N(P) = L$ genau dann wenn:

1. L präfixfrei (kein Wort ist der Anfang eines anderen Wortes) ist
2. Es einen DPDA P' , der über leeren Stack akzeptiert, gibt mit $L(P) = L$

Ein DPDA der durch leeren Stack akzeptiert erkennt nicht mal alle reguläre Sprachen (z.B.: $L = \{0\}^*$), allerdings kann er auch nicht-reguläre Sprachen (z.B. $L = \{wcw^R | w \in \{0, 1\}^*\}$) erkennen.

DPDA und kfG

Gegeben sei eine Sprache L und ein DPDA P .

- $L = N(P) \Rightarrow L$ hat eine eindeutige kontextfreie Grammatik.
- $L = L(P) \Rightarrow L$ hat eine eindeutige kontextfreie Grammatik.
- L hat eine eindeutige kontextfreie Grammatik heisst aber nicht, dass es einen passenden DPDA gibt. (z.B. Palindrome)

Eigenschaften kontextfreier Sprachen

Seien L_1 und L_2 kontextfreie Sprachen über Σ . Dann gelten:

Vereinigung	$L_1 \cup L_2$ ist kontextfrei
Durchschnitt	$L_1 \cap L_2$ ist nicht kontextfrei
Komplement	L_1^C kann kontextfrei sein
Verkettung	$L_1 + L_2$ ist kontextfrei
Differenz	$L_1 - L_2$ kann kontextfrei sein
Hülle	L_1^* und L_1^+ sind kontextfrei
Homomorphismus	$h(L_1)$ und $h^{-1}(L_1)$ sind kontextfrei
Spiegelung	L_1^R ist eine kontextfrei

Entscheidbarkeit kontextfreier Sprachen

Gegeben sei ein kontextfreie Sprache L und eine kontextfreie Grammatik G	
Ist L leer?	entscheidbar
$w \in L$?	entscheidbar
Ist L inhärent mehrdeutig?	nicht entscheidbar
Ist G mehrdeutig	nicht entscheidbar
$L_1 \cap L_2 = \emptyset$?	nicht entscheidbar
$L_1 = L_2$?	nicht entscheidbar

Nicht kontextfreie Sprachen

Pumping-Lemma

Sei L eine kontextfreie Sprache. Dann gibt es eine eine Konstante n , so dass jede Zeichenreihe $w \in L$ und die Länge von $z \geq 0$ in fünf Teilzeichenreihen $w = uvxyz$ zerlegt werden kann, dass:

- $|vxy| \leq n$
- $vx \neq \varepsilon$
- $uv^kxy^kz \in L$ für alle $k \geq 0$

Eine mittlere Teilzeichenreihe (vxy) wird beliebig oft wiederholt.

Beispiel: $L = \{0^m 1^m 2^m \mid m > 0\}$

Ist L kontextfrei, dann gibt es eine Konstante n , so dass $0^n 1^n 2^n$ ebenfalls in L ist: Nun muss w in $uvxyz$ so zerlegt werden, dass $vx \neq \varepsilon$ und $|vxy| \leq n$ gilt. vxy kann aber nicht zugleich 0 und 2 enthalten (sonst wäre der Abstand zwischen der letzten 0 und der ersten $2 \neq n + 1$)

Fall I: $2 \notin vxy \Rightarrow 0 \vee 1 \in uwz$: Widerspruch zur Annahme $uwz \in L$

Fall II: $0 \notin vxy \Rightarrow 1 \vee 2 \in uwz$: Widerspruch zur Annahme $uwz \in L$

Turing-Maschine (TM)

Hintergrund

Gibt es einen Algorithmus der die Wahrheit jeder mathematischen Aussage ermittelt?

Ja für Aussagenlogik

Nein für die Prädikatenlogik (Gödel, 1930)

Definition

Eine Turing Maschine kann alle möglichen Berechnungen ausführen und wird als 7-Tupel definiert:

$$\mathcal{M} = (Q, \Sigma, \Gamma, \delta, q_0, B, F)$$

Q, Σ, q_0, F wie gehabt (Zustände, Alphabet, ...)


Γ endliches Bandalphabet ($\Sigma \subset \Gamma$)

δ Übergangsfunktion: $Q \times \Gamma \rightarrow Q \times \Gamma \times D$

d. h. $\delta(q_v, \sigma) = (q_n, \gamma, d)$. D steht für die Bewegung des Lese/Schreibkopfes (L = links, 0 = keine, R = rechts)

B „Leerzeichen“, $B \in \Gamma \wedge B \notin \Sigma$

- Das Band besteht aus einzelnen Zellen, die ein Element aus Γ enthalten können
- Zu Beginn enthält das Band die „Eingabe“ – eine endliche Zeichreihe aus Σ . (Alle anderen enthalten das Leerzeichen B)
- Der Lese/Schreibkopf kann jeweils eine Zelle lesen und schreiben



Turing-Maschine mit der Anfangskonfiguration $w = \sigma_1 \sigma_2 \dots \sigma_n$

Konfiguration/Instanzdeskriptor Gegeben sei eine Turing-Maschine \mathcal{M} . Die Zeichenreihe $X_1 X_2 \dots X_{i-1} q X_i X_{i+1} \dots X_n$ heisst Konfiguration von \mathcal{M} . Dabei ist q der Zustand von \mathcal{M} , X_i die Position des Lese/Schreibkopfes. Alle anderen $X_a, a \neq i$ können leer sein.

Bewegung Gegeben sei eine Turing-Maschine \mathcal{M} . Mit der Konfiguration $X_1 X_2 \dots X_{i-1} q X_i X_{i+1} \dots X_n$

- Linksbewegung: $\delta(q, X_i) = (p, Y, L)$ d. h. $X_i \rightarrow Y$, Kopf neu bei X_{i-1}
 - $i = 1 \Rightarrow q X_1 \dots X_n \vdash_{\mathcal{M}} p B Y X_2 \dots X_n$
 - $i = n \wedge Y = B \Rightarrow X_1 \dots q X_n \vdash_{\mathcal{M}} X_1 \dots X_{n-2} p X_{n-1}$
- Rechtsbewegung: $\delta(q, X_i) = (p, Y, R)$ d. h. $X_i \rightarrow Y$, Kopf neu bei X_{i+1}
 - $i = n \Rightarrow X_1 \dots X_{n-1} q X_n \vdash_{\mathcal{M}} X_1 \dots X_{n-2} Y p B$
 - $i = 1 \wedge Y = B \Rightarrow q X_1 \dots X_n \vdash_{\mathcal{M}} p X_2 \dots X_n$
- 0-Bewegung: $\delta(q, X_i) = (p, Y, 0)$ d. h. $X_i \rightarrow Y$ ohne dass sich der Kopf bewegt

Berechnung Gegeben sei eine Turing-Maschine \mathcal{M} und ein Folge von Konfigurationen K_1, \dots, K_n für die paarweise gilt: $(K_i) \vdash_{\mathcal{M}} (K_{i+1})$ ist eine Bewegung in \mathcal{M} , dann stellt die Folge

eine Berechnung von \mathcal{M} dar: $(K_1) \vdash_{\mathcal{M}} (K_n)$

- Die Berechnung einer TM ist abgeschlossen wenn $\delta(q, x)$ nicht definiert ist. Sie hält an
- Zahlen werden als Blöcke von „0“ dargestellt. Mehrere Parameter werden mit „1“ getrennt
- Ist eine Funktion f für alle Parameter definiert, dann ist f eine total rekursive Funktion ($\hat{=}$ rekursive Sprache)
- Wird f allgemein von TM berechnet, ist f eine partiell rekursive Funktion ($\hat{=}$ rekursiv aufzählbare Sprache)
- Alle üblichen mathematischen Funktionen $(+, -, \cdot, \div, n!, \log, a^b, \dots)$ sind total rekursive Funktionen


Rekursiv aufzählbare Sprache Die Menge aller Zeichenreihen $w \in \Sigma^*$ für die eine Turing-Maschine \mathcal{M} in einen akzeptierenden Endzustand übergeht:

$$L(\mathcal{M}) = \{w \mid (q_0 w) \vdash (\alpha p \beta) \text{ für ein } p \in F \wedge \alpha, \beta \in \Gamma^*\}$$

w ist die Eingabe, \mathcal{M} startet in q_0 , der Lese/Schreibkopf beginnt beim ersten Zeichen von w . Solange die TM eine Eingabe bearbeitet und nicht anhält, kann nicht entschieden werden ob $w \in L(\mathcal{M})$.

Erkannt werden u. a. alle kontextfreien Sprachen. Es gilt: rekursive Sprache \subset rekursiv aufzählbare Sprachen.

Beispiel Turing-Maschine für $L = \{0^n 1^n \mid n \in \mathbb{N}\}$



$$\mathcal{M} = (Q, \Sigma, \Gamma, \delta, q_0, B, F)$$

$$Q = \{q_0, q_1, \dots, q_4\}$$

$$\Gamma = \{0, 1, X, Y, B\}$$

$$F = \{q_4\}$$

$$\delta(q_0, 0) = (q_1, X, R)$$

$$\delta(q_1, 0) = (q_1, 0, R)$$

$$\delta(q_1, Y) = (q_2, Y, R)$$

...

$$\Sigma = \{0, 1\}$$

$$q_0 = q_0$$

$$\delta(q_0, Y) = (q_3, Y, R)$$

$$\delta(q_1, 1) = (q_2, Y, L)$$

$$\delta(q_2, 0) = (q_2, 0, L)$$

Berechnung von $w = 01$: $q_0 0 1 \vdash q_0 1 X Y B q_4 B$

$$q_0 0 1 \vdash X q_1 1 \vdash q_2 X Y \vdash X q_0 Y \vdash X Y q_3 B \vdash X Y B q_4 B$$

Codierung einer TM

- Jeder Zeichenreihe über Σ wird eine ganze Zahl in lexikographischer Ordnung zugewiesen: $1 = \varepsilon, n = \sigma_{n-1} \in \Sigma$
- Die Zustände Q der TM \mathcal{M} werden codiert als: q_1 =Start-, q_2 =akzeptierender Endzustand, $q_3 \dots q_n$ übrige Zustände.
- Die Bandsymbole Γ von \mathcal{M} werden codiert als: $x_1 = 0, x_2 = 1, x_3$ =Blank, $x_4 \dots x_n$ für alle weiteren Symbole
- Die Richtung des Lese-Schreibkopfes wird codiert als: d_1 = links, d_2 = rechts
- Die Übergangsfunktion δ von \mathcal{M} wird codiert über die Zeichenreihe $0^i 10^j 10^k 10^l 10^m$, Übergangsfunktionen werden durch 11 voneinander getrennt

So lässt sich jede TM \mathcal{M} als Zahl darstellen:

$$\mathcal{M} = (\{q_1, q_2, q_3\}, \{0, 1\}, \{0, 1, B\}, \delta, q_1, B, \{q_2\})$$

$$\delta = \{\delta(q_1, 1) = (q_3, 0, R), \delta(q_3, 0) = (q_1, 1, L),$$

$$\delta(q_3, 1) = (q_2, 0, R), \delta(q_3, B) = (q_3, 0, L)\}$$

Die Codierung $c(\mathcal{M})$ lautet dann:

$$\delta(q_1, 1) = (q_3, 0, R) \mapsto 0100100010100$$

$$\delta(q_3, 0) = (q_1, 1, L) \mapsto 000101010010$$

$$\delta(q_3, 1) = (q_2, 0, R) \mapsto 00010010010100$$

$$\delta(q_3, B) = (q_3, 0, L) \mapsto 000100010001010$$

$$\Rightarrow c(\mathcal{M}) = 0100100010100110001010100101100010010010100$$

$$11000100010001010_2 = 1\,480\,103\,890\,654\,955\,658\,10$$

Sonstiges

- Es existieren Varianten von TM: Speicher, Mehrspur, Mehrband, Semiunendliches Band, Leerzeichenverbot. Alle Varianten sind gleich mächtig
- Eine TM ist gleich mächtig wie ein PDA mit 2 Stacks oder einer Zählmaschine mit zwei Zählern
- Eine TM kann Aufgaben an „Unterprogramme“, d. h. Unter-TMs delegieren
- Jede TM mit n akzeptierenden Zuständen kann in eine TM mit nur einem akzeptierenden Zustand überführt werden

Berechenbarkeit/Rekursionstheorie

(Kurt Gödel, Alonzo Church, Alan Turing, 30er Jahre)

Computer \Leftrightarrow Turing-Maschine

Berechenbarkeit Eine Funktion f ist berechenbar, wenn es eine TM \mathcal{M} gibt, die f berechnet. D.h. es kann ein Algorithmus gefunden werden, der f berechnet
Jede TM kann *partiell rekursive Funktionen*/rekursive aufzählbare Sprachen berechnen/erkennen

Primitiv rekursive Funktion Eine Funktion, die über mindestens ein Abbruchkriterium verfügt und sich selbst aufruft. Für primitiv rekursive Funktionen gilt: Eine TM hält für alle Eingaben.
Beispiele: Addition, Multiplikation, Potenz, Fibonacci-Zahlen

Partiell rekursive Funktion (μ -rekursive Funktion) Eine Funktion, welche die primitiv rekursiven Funktionen um den μ -Operator erweitert. Der μ bildet dabei eine $k + 1$ stellige Funktion auf ein k stellige ab. (Beispiele: Nachfolgerfunktion $\sigma(n) = n + 1$, Ackermannfunktion (s. u.)). Somit gilt:

primitiv rekursive Funktionen $\subsetneq \mu$ – rekursive Funktionen

Rekursiv aufzählbar Es gibt einen Algorithmus, um allen Elementen einer Menge eine natürliche Zahl n zuzuordnen

Church'sche These Die Klasse der Turing-berechenbaren Funktionen ist genau die Klasse der „intuitiv“ berechenbaren Funktionen

Rekursive Sprache Eine Sprache L heisst rekursiv, wenn $L = L(\mathcal{M})$ für eine TM \mathcal{M} ist und für jedes w gilt:

- $w \in L \Rightarrow \mathcal{M}$ hält und akzeptiert
- $w \notin L \Rightarrow \mathcal{M}$ hält und akzeptiert nicht

Programm-Typen

Als Beispiel ist jeweils die Addition von $x + y$ aufgeführt.

GOTO-Programme

Endliche Anzahl von Variablen $a_1, \dots a_n$ und Konstanten $K_1, \dots K_n$
Jede Anweisung (Zeile) ist nummeriert
Fünf verschiedene Anweisungen:

- | | | |
|---------------------------------|---|---------------------|
| 1. Zuweisung & „+“: $a = a + K$ | 1 | k := x |
| 2. Zuweisung & „−“: $a = a - K$ | 2 | l := y |
| 3. Sprunganw. (GOTO Zeile n) | 3 | k := k + 1 |
| 4. Verzweigung (IF ... ELSE) | 4 | l := l - 1 |
| 5. Stopp-Anweisung | 5 | if (l > 0) goto 3 |
| | 6 | end |

GOTO-Programme stehen für unstrukturierten Code (Programmiersprache BASIC). Es gilt:

GOTO-Programme \Leftrightarrow Turing-Maschine

WHILE-Programme

Endliche Anzahl Variablen $a_1, \dots a_n$ und Konstanten $K_1, \dots K_n$
Drei verschiedene Anweisungen:

- | | |
|---|--------------------|
| 1. Zuweisung & „+“: $a = a + K$ | k := x |
| 2. Zuweisung & „−“: $a = a - K$ | l := y |
| 3. Bedingte Schleife (WHILE ... DO ... END) | while (l > 0) do |
| | k := k + 1 |
| | l := l - 1 |
| | end |

Jedes beliebige WHILE-Programm kann durch eine WHILE-Programm mit genau einer Schleife ersetzt werden!
WHILE-Programmen stehen für strukturierten Code (Programmiersprachen Pascal, C, Java, ...). Es gilt:

WHILE-Programme \Leftrightarrow GOTO-Programme

LOOP-Programme

Endliche Anzahl Variablen $a_1, \dots a_n$ und Konstanten $K_1, \dots K_n$
Drei verschiedene Anweisungen:

- | | |
|--|------------|
| 1. Zuweisung & „+“: $a = a + K$ | k := x |
| 2. Zuweisung & „−“: $a = a - K$ | l := y |
| 3. Feste Schleife (LOOP DO ... END) | loop l do |
| Die Anzahl der Schleifen ist zu Beginn festgelegt (FOR NEXT) | k := k + 1 |
| | end |

Es gilt:

- Jedes LOOP-Programm kann durch ein WHILE- oder GOTO-Programm ersetzt werden
- Nicht jedes WHILE-/GOTO-Programm kann durch ein LOOP-Programm ersetzt werden
- LOOP-Programme entsprechen den primitiv rekursiven Funktionen und terminieren immer
- GOTO-/WHILE-Programme entsprechen den μ -rekursiven Funktionen und terminieren nicht immer

Partiell rekursive Funktionen

Mit Hilfe von struktureller Induktion und Widerspruch kann gezeigt werden, dass es Funktionen (z. B. Ackermannfunktion) gibt, die schneller wachsen als primitiv rekursive Funktionen. Die Ackermannfunktion ist rekursiv, aber nicht primitiv rekursiv.

$$\begin{aligned} a(0, m) &= m + 1 \\ a(n + 1, 0) &= a(n, 1) \\ a(n + 1, m + 1) &= a(n, a(n + 1, m)) \end{aligned}$$

Entscheidbarkeit

Die Entscheidbarkeit eines Problems L lässt sich unterteilen:
Entscheidbar sind alle Probleme/Sprachen, die rekursiv sind. D.h. eine TM hält für alle rekursiven Eingaben.

Semi-entscheidbar sind alle Probleme/Sprachen, die zwar rekursiv aufzählbar, aber nicht rekursiv sind. D.h. eine TM hält für alle rekursiv aufzählbaren Eingaben.

Unentscheidbar sind alle Probleme/Sprachen, die nicht rekursiv aufzählbar sind.

Unentscheidbare Probleme

Diagonalisierungssprache L_d (codiert eine TM)

Bildung:
Jede \mathcal{M}_i lässt sich als Zeichenreihe w_i darstellen (Codierung TM). In einer Tabelle mit allen w_i als Zeilen und w_i als Spalten steht in Zelle z, s ob $\mathcal{M}_z \mathcal{M}_s$ als Eingabe akzeptiert (Wert: 1) oder nicht (Wert: 0) L_d ist die Sprache aus allen denen Wörtern, die Turing-Maschinen codieren, die sich selbst nicht als Eingabewort akzeptieren.

$$L_d = \{w_i | w_i \notin L(\mathcal{M}_i)\}$$

$\Rightarrow L_d$ ist nicht rekursiv aufzählbar \Rightarrow nicht entscheidbar.

Semi-entscheidbare Probleme

Halteproblem

Satz. Es ist unentscheidbar, ob eine TM für jedes codierte Paar $(c(\mathcal{M}), w)$ als Eingabe hält oder nicht.

\mathcal{M} hält nur für Paare bei denen $w \in L_U$ ist.

$$\Rightarrow \{L_{\text{rekursiv}}\} \subsetneq \{L_{\text{rekursiv aufzählbar}}\} \not\subset \{L_{\text{nicht rekursiv aufzählbar}}\}$$

Game-of-Life

Die Frage, ob eine gegebene Anfangskonfiguration (w) zu ein stabilen oder periodischen Muster, oder dem kompletten Aussterben führt, kann nicht immer beantwortet werden.

Collatz-Zahlen

Gegeben sei die Collatz-Funktion col:

$$\text{col}(n) = \begin{cases} n/2 & \text{falls } n \equiv 0 \pmod{2} \\ 3n + 1 & \text{sonst} \end{cases}$$

Wendet man die Funktion auf das Ergebnis einer ursprüngliche Eingabe $n \in \mathbb{N}$ wiederholt an, entsteht die Collatz-Folge. Sie endet bei $n = 1$. Es ist unbekannt, ob die Menge der Collatz-Zahlen rekursiv ist.

Fleissige Biber

Ein fleissiger Biber ist eine Turingmaschine mit dem Alphabet $\Sigma = \{0, 1\}$ und n Zuständen, die hält und zuvor auf ein leeres (aus Nullen bestehendes) Band die maximale Anzahl k_n von Einsen schreibt, verglichen mit allen anderen haltenden Turingmaschinen mit ebenfalls n Zuständen (Nur Nicht-haltende-Turingmaschinen schreiben mehr einsen). Die Fleissige-Biber-Funktion ist definiert als $\sum(n) = k_n$. Es ist nicht entscheidbar, ob eine gegebene TM tatsächlich eine Kette maximaler Länge schreibt.

